



不确定性知识表示与推理

Uncertain Knowledge Representation and Reasoning



授课对象：计算机科学与技术专业 二年级

课程名称：人工智能（专业必修）

节选内容：第四章 不确定性知识表示与推理

课程学分：3学分



贝叶斯网络

独立性带给我们什么？

- 假设布尔变量 $X_1, X_2, \dots, X_n$ 彼此相互独立(即, 每个子集与其他所有子集相互独立)
- 我们可以仅使用 n 个参数 (linear) 来指定完整的联合分布 (probability function over all vectors of values), 而不是 $2^n - 1$ 个参数 (exponential) **只使用n个参数(线性)来计算完整的联合分布**
- 只需指定 $Pr(X_1 = true), \dots, Pr(X_n = true)$ (即, 对所有 i 指定 $Pr(X_i = true)$)
- 我们可以轻松恢复任何基本事件的概率, 例如:
- $Pr(X_1 \neg X_2 X_3 X_4) = Pr(X_1)(1 - Pr(X_2))Pr(X_3)Pr(X_4)$

The Value of Independence 独立性的价值

- 完全独立性将表示和推理的复杂度从 $O(2^n)$ 降低到 $O(n)$!
- 不幸的是, 这种完全的相互独立性很少见, 大多数现实领域并不具备这种特性。


完全的相互独立性不存在了!

- 幸运的是, 大多数领域确实表现出相当程度的条件独立性。而条件独立性时常有!
- 我们可以利用条件独立性来进行表示和推理。
- Bayesian networks do just this

利用条件独立性

想象这么一个故事:

- If Craig woke up too early (**E**), Craig probably needs coffee (**C**);
- if **C**, he's likely angry (**A**).
- If **A**, there is an increased chance of a burst blood vessel (**B**).
- If **B**, Craig is quite likely to be hospitalized (**H**).



E - Craig woke too early A - Craig is angry H - Craig hospitalized
C - Craig needs coffee B - Craig burst a blood vessel

利用条件独立性




- 如果掌握了关于 E, C, A, or B, 你对 $Pr(H)$ 的评估会发生变化。
对E, C, A, B信息的掌握影响对 $Pr(H)$ 的评估
 - 例如, 如果这些变量中的任意一个被观测为真, 你会增加 $Pr(h)$ 并减少 $Pr(\neg h)$.
 - 因此 H **不独立于** (not independent of) E, C, A, 或 B。
- 但是, 如果你已经知道 B 的取值 (真或假), 那么再学习 E, C, 或 A 的取值, 将不会影响 $Pr(H)$ 。这些因素对 H 的影响是通过它们对 B 的影响来间接传递的。
 - Craig doesn't get sent to the hospital because he's angry, he gets sent because he's had a burst blood vessel.
 - So H is **independent** of E, and C, and A, **given** B

利用条件独立性



- 类似地:
 - B is independent of E, and C, given A
 - A is independent of E, given C
- 因此:
 - $Pr(H|B, \{A, C, E\}) = Pr(H|B)$
 - $Pr(B|A, \{C, E\}) = Pr(B|A)$
 - $Pr(A|C, \{E\}) = Pr(A|C)$
 - $Pr(C|E)$ 和 $Pr(E)$ 无法进一步简化。

独立性带给我们什么？



根据链式法则 (chain rule) (适用于任意 $H \dots E$ 的实例化):

$$P(H, B, A, C, E) = P(H|B, A, C, E) P(B|A, C, E) P(A|C, E) P(C|E) P(E)$$

$$2^4 + 2^3 + 2^2 + 2^1 + 2^0 = 2^5 - 1$$


根据我们的条件独立性假设:

$$P(H, B, A, C, E) = P(H|B) P(B|A) P(A|C) P(C|E) P(E)$$

我们可以通过指定五个 **局部条件分布** (local conditional distributions (joints))

$$P(H|B); P(B|A); P(A|C); P(C|E); \text{ and } P(E)$$

示例量化 (Example quantification)




其中一般的参数可以由“1 减去”另一半得到。

因此，指定完整的联合分布仅需要 $9(1+2+2+2+2)$ 个参数,而不是显式表示所需的 31 个参数。

- 变量数量的线性增长，而非指数增长！
- 如果依赖关系呈链状结构，则通常是线性增长。

推理很简单 (Inference is Easy)




如何计算 $P(a)$? 使用 summing out rule:

$$\begin{aligned}\Pr(a) &= \sum_{c_i \in \text{Dom}(C)} \Pr(a \mid c_i) \Pr(c_i) \\ &= \sum_{c_i \in \text{Dom}(C)} \Pr(a \mid c_i) \sum_{e_i \in \text{Dom}(E)} \Pr(c_i \mid e_i) \Pr(e_i)\end{aligned}$$

这些项全部来自我们指定的局部分布!

推理很简单 (Inference is Easy)



计算 $P(\sim A)$?


$P(A C)$	$= 0.7$
$P(\sim A C)$	$= 0.3$
$P(A \sim C)$	$= 0.0$
$P(\sim A \sim C)$	$= 1.0$

Bayesian Networks: graph + tables 一图一表一BN

- 上述结构是一个 Bayesian network (贝叶斯网络) .
- BN 是一种图形化表示 (graphical representation) , 它描述了一组变量之间的直接依赖关系, 并结合一组 条件概率表示 (conditional probability tables (CPTs)) 来量化这些依赖关系的强度。

贝叶斯网络在此基础上进行了有趣的泛化, 从而提供了一种在不确定性下进行高效表示和推理的方法。

一图: 有向无环图
一表: 条件概率表



贝叶斯网络 (Bayesian Networks)

一个以变量 $\{X_1, X_2, \dots, X_n\}$ 为基础的 BN 由以下部分组成:


- 一个有向无环图 **DAG** (directed acyclic graph), 其节点为变量。
- 一组条件概率表 **CPTs** (conditional probability tables)
对于每个 X_i $Pr(X_i | Par(X_i))$

关键概念:

- 父节点 **parents** of a node: $Par(X_i)$
- 子节点 **children** of a node
- 后代 **descendants** of a node
- 祖先 **ancestors** of a node
- 家族 **family**: 由 X_i 及其父节点组成的节点集合



Example (此处变量取二值)



- 一对条件概率表 CPTS 展示了 11 个变量。
- 显示联合需要 $2^{11} - 1 = 2047$ 参数!
- BN 仅需 27 参数 (每个 CPT 的条目数已列出)

Semantics of Bayes Nets

- 贝叶斯网络指定了网络中变量的联合分布可以写成以下乘积分解形式:

$$Pr(X_1, X_2, \dots, X_n) = Pr(X_n | Par(X_n)) * Pr(X_{n-1} | Par(X_{n-1})) \\ * \dots * Pr(X_1 | Par(X_1))$$

- 该方程适用于变量 $X_1, X_2, \dots, X_n$ 的任意值 $d_1, d_2, \dots, d_n$.
- 例如, 假设 X_1, X_2, X_3 的域为 $Dom[X_i] = \{a, b, c\}$ 则有:

$$Pr(X_1, X_2, X_3) = P(X_3 | X_2)P(X_2)P(X_1)$$

- 则:

$$Pr(X_1 = a, X_2 = a, X_3 = a) = P(X_3 = a | X_2 = a)P(X_2 = a)P(X_1 = a)$$



贝叶斯网络：案例分析

Another Bayesian Network

A: Aameri gives the lecture

S: It is sunny out

L: The lecturer arrives late

假设所有讲师在恶劣天气下可能会迟到。有些讲师可能比其他讲师更容易迟到。



贝叶斯网络：案例分析

A: Aameri gives the lecture

S: It is sunny out

L: The lecturer arrives late

假设所有讲师在恶劣天气下可能会迟到。有些讲师可能比其他讲师更容易迟到。

我们从已知条件开始:

$$P(S|A) = P(S), P(S) = 0.3, P(A) = 0.5$$

迟到 (L) 与天气 (S) 和讲师 (A) 并不独立。
我们需要为 S 和 A 的所有取值形式化 $P(L|S,A)$ 。



贝叶斯网络：案例分析

A: Aameri gives the lecture

S: It is sunny out

L: The lecturer arrives late

$$P(S|A) = P(S), P(S) = 0.3, P(A) = 0.5$$

$$P(L|S,A) = 0.05, P(L|S,\sim A) = 0.1, P(L|\sim S,A) = 0.1, P(L|\sim S,\sim A) = 0.2$$

由于条件独立性，我们只需要 6 个值来指定完整的联合分布，
而不是 7 个值 $7=2^3-1$ 。

条件独立性带来了计算上的节省！


贝叶斯网络：案例分析

Drawing the Network

$$P(S|A) = P(S), P(S) = 0.3, P(A) = 0.5$$

$$P(L|S,A) = 0.05, P(L|S,\sim A) = 0.1, P(L|\sim S,A) = 0.1, P(L|\sim S,\sim A) = 0.2$$

A	T	0.5
A	F	0.5




S	T	0.3
S	F	0.7


	A	S	$P(L=T A,S)$
L	T	T	0.05
L	T	F	0.1
L	F	T	0.1
L	F	F	0.2

贝叶斯网络：案例分析

A	T	0.5
A	F	0.5




Read the absence of an arrow between S and A to mean "It will not help me predict A if I just know the value of S"



S	T	0.3
S	F	0.7

Read the two arrows into L to mean "If I want to know the value of L it may help me to know A and to know S."



	A	S	$P(L=T A,S)$
L	T	T	0.05
L	T	F	0.1
L	F	T	0.1
L	F	F	0.2



贝叶斯网络：案例分析

Back to the network

现在假设我们有以下三个事件:

A: Aameri gives the lecture ($\sim A$: Allin gives the lecture)

L: The lecturer arrives late

R : The lecturer concerns Reasoning with Bayes' Nets

已知:

- Allin has a higher chance of being late than Aameri. ($\sim A$)
- Allin has a higher chance of giving lectures about reasoning with BNs


我们的图中存在哪些独立性?

贝叶斯网络：案例分析

一旦你知道讲师是谁，那么他们是否迟到就不会影响讲座是否涉及贝叶斯网络推理，即：

$$P(R|A,L) = P(R|A)$$

$$P(R| \sim A,L) = P(R| \sim A)$$



Read this diagram as
“Given knowledge of A,
knowing about L won’t tell anything
more about R.”



贝叶斯网络：案例分析

Try to Build a Bayes Net

A: Aameri gives the lecture

L: The lecturer arrives late

R: The lecturer concerns Reasoning with Bayes' Nets

S: It is sunny out

T: The lecture starts on time.

- T 仅受 L 直接影响 (i.e. T is conditionally independent of R, A, S given L)
- L 仅受 A 和 S 直接影响 (i.e. L is conditionally independent of R given A & S)
- R 仅受 A 直接影响 (i.e. R is conditionally independent of L, S, given A)
- A 和 S 相互独立



贝叶斯网络：案例分析

Building a Bayes Net


A: Aameri gives the lecture

L: The lecturer arrives late

R: The lecturer concerns Reasoning with Bayes' Nets

S: It is sunny out

T: Lecture starts on time.



Step One: Add variables



贝叶斯网络：案例分析


A: Aameri gives the lecture

L: The lecturer arrives late

R: The lecturer concerns Reasoning with Bayes' Nets

S: It is sunny out

T: Lecture starts on time.




Step Two: add links.

链式结构必须是无环的。

如果节点 Y 指定父节点 $X_1, X_2, \dots, X_n$, 则意味着在给定 $\{X_1, X_2, \dots, X_n\}$ 的情况下, Y 与任何非 Y 后代 (descendent) 的变量条件独立。

贝叶斯网络：案例分析



A: Aameri gives the lecture

L: The lecturer arrives late

R: The lecturer concerns Reasoning with Bayes' Nets

S: It is sunny out


T: Lecture starts on time.

Step Three: add a conditional probability table (CPT) for each node.

X 的表必须定义 $P(X|\text{Parents})$, 并涵盖所有可能的父节点取值组合。



贝叶斯网络：案例分析



A: Aameri gives the lecture

L: The lecturer arrives late

R: The lecturer concerns Reasoning
with Bayes' Nets

S: It is sunny out

T: Lecture starts on time.

你可以从贝叶斯网络中推导出许多概率关系。

需要注意的是，即使变量之间没有直接连接，它们仍可能是相关的。

贝叶斯网络：案例分析

始终可以使用任意变量顺序构造一个贝叶斯网络，以表示变量 $X_1, X_2, \dots, X_n$ 的任何分布。

取任意变量顺序（例如给定的顺序）。根据链式法则，我们得到：

$$\Pr(X_1, \dots, X_n) = \Pr(X_n | X_1, \dots, X_{n-1}) \Pr(X_{n-1} | X_1, \dots, X_{n-2}) \dots \Pr(X_1)$$

现在，对于每个 X_i 遍历其条件集合 $X_1, \dots, X_{i-1}$ ，并逐步移除所有使得 X_i 在给定其余变量的情况下与 X_j 条件独立的变量 X_j 。重复此过程，直到无法再移除变量。

最终的乘积表示一个贝叶斯网络。

构建贝叶斯网络

始终可以使用任意变量顺序构造一个贝叶斯网络，以表示变量 $X_1, X_2, \dots, X_n$ 的任何分布。

Step 1. 使用任意变量顺序应用链式法则。(We will see later that you may wish to use causality or some other property to guide the variable ordering. 因果关系或其他准则引导排序)

$$Pr(X_1, \dots, X_n) = Pr(X_n | X_1, \dots, X_{n-1}) Pr(X_{n-1} | X_1, \dots, X_{n-2}) \dots Pr(X_1)$$

Step 2. 对于每个 X_i 遍历其条件集合 $X_1, \dots, X_{i-1}$ 并逐步移除所有使得 X_i 在给定其余变量的情况下与 X_j 条件独立的变量 X_j 。重复此过程，直到无法再移除变量。



构建贝叶斯网络

- Step 2 将产生一个乘积分解 (decomposition)
 $Pr(X_n | Par(X_n))Pr(X_{n-1} | Par(X_{n-1})) \dots Pr(X_1)$
- 要构建贝叶斯网络, 需创建一个有向无环图 (DAG), 其中每个变量对应一个节点, 变量 X_i 的条件集合 $Par(X_i)$ 在 DAG 中作为 X_i 父节点。



贝叶斯网络：案例分析

- 为每个家族 (family , variable and its parents) 指定条件概率表(CPT)。
- 通常, 我们用一个表来表示 CPT, 该表将 $\{X_i, Par(X_i)\}$ 的每种取值映射到 X_i 在给定 $Par(X_i)$ 取特定值时的概率。
- 如果每个变量有 d 个不同的取值,则需要一个大小为 $d^{|\{X_i, Par(X_i)\}|}$ 的表。
- 即该表的规模随着父节点集合的大小呈指数增长。



Variable Ordering Matters - Causal Intuitions

- 贝叶斯网络可以使用任意变量顺序构造。 **变量序列**
- 然而，某些顺序可能会导致贝叶斯网络中具有非常大的父节点集合，这将需要指数级的存储空间，并且（如我们稍后所见）推理过程的时间复杂度也是指数级的。
- 从经验和概念上来看，一个构造贝叶斯网络的有效方法是基于因果关系的变量排序。 **基于因果关系的变量序列可以获得更加自然紧致的贝叶斯网络结构**

Causal Intuitions

- Malaria, flu, cold都会导致身体 aches 。因此，使用因果关系排序，将原因排在效果之前： Malaria, Flu, Cold, Aches 。


$$Pr(M, F, C, A) = Pr(A | M, F, C)Pr(C | M, F)Pr(F | M)Pr(M)$$

- 这些疾病都会影响 aches 的概率，因此第一个条件概率保持不变。
- 合理的假设是这些疾病彼此独立：患有或不患有某种疾病不会改变患其他疾病的概率。
- 因此 $Pr(C | M, F) = Pr(C)$, $Pr(F | M) = Pr(F)$

Causal Intuitions

这将产生一个相对简单的贝叶斯网络。

我们只需要一个大的条件概率表（CPT），涉及“Aches”这一家族。



Causal Intuitions


- 假设我们使用相反的排序构建贝叶斯网络: Aches, Cold, Flu, Malaria.

$$Pr(A, C, F, M) = Pr(M | A, C, F) Pr(F | A, C) Pr(C | A) Pr(A)$$

- 我们能否简化 $Pr(M | A, C, F)$? **No**
 - 显然, 疟疾 (Malaria) 的概率会受到疼痛 (aches) 的影响。
 - 那么, 知道疼痛 (aches) 和感冒 (cold), 或者知道疼痛 (aches)、感冒 (cold) 和流感 (flu) 呢?
 - 疟疾 (Malaria) 的概率确实受到这两个附加信息的影响。
 - 知道感冒 (cold) 和流感 (flu) 会降低疼痛 (aches) 的概率, 表明疟疾 (Malaria), 因为它们会“解释掉”疼痛 (aches) 的影响!
 - 同样地, 我们无法简化 $Pr(F | A, C)$.
- $Pr(C | A) \neq Pr(C)$

Causal Intuitions

我们得到一个更加复杂的贝叶斯网络。实际上，我们并没有比显式表示完整联合分布（即表示每个原子事件的概率）节省任何计算。



基于因果关系的变量序列可以获得更加自然紧致的贝叶斯网络结构

示例 (Binary valued Variables)

$\Pr(A, B, C, D, E, F, G, H, I, J, K) =$

$\Pr(A)$

$\times \Pr(B)$

$\times \Pr(C | A)$

$\times \Pr(D | A, B)$

$\times \Pr(E | C)$

$\times \Pr(F | D)$


$\times \Pr(G)$

$\times \Pr(H | E, F)$

$\times \Pr(I | F, G)$

$\times \Pr(J | H, I)$

$\times \Pr(K | I)$






The Classic Burglary Example

- I'm at work, neighbour John calls to say my alarm is ringing, but neighbour Mary doesn't call. Sometimes it's set off by minor earthquakes. Is there a burglar?
- Variables: **Burglary**入室盗窃, **Earthquake**, **Alarm**, **JohnCalls**, **MaryCalls**
- Network topology reflects "causal" knowledge:
 - A burglar can set the alarm off
 - An earthquake can set the alarm off The
 - alarm can cause Mary to call
 - The alarm can cause John to call

The Classic Burglary Example

- A burglary can set the alarm off
- An earthquake can set the alarm off
- The alarm can cause Mary to call
- The alarm can cause John to call

*Note that these tables only provide the probability that X_i is true.
(E.g., $Pr(A \text{ is true} | B, E)$)
The probability that X_i is false is 1- these values*



Number of Parameters: $1 + 1 + 4 + 2 + 2 = 10$ (vs. $2^5 - 1 = 31$)

Using the Bayes Net:

$$Pr(B, E, A, J, M) = Pr(M | A) Pr(J | A) Pr(A | B, E) Pr(B) Pr(E)$$

构建贝叶斯网络的示例

- 之前我们选择了一个因果顺序。
- 现在假设我们选择以下排序
MaryCalls (M), JohnCalls (J), Alarm (A), Burglary(B),
Earthquake(E), *i.e.*, **M,J,A,B,E**
- 这些“排序”是贝叶斯网络有向无环图 (DAG) 中箭头的排序, 与链式法则中变量的排序相反, *i.e.*,
$$Pr(M,J,A,B,E) = Pr(E | B, A, J, M) * Pr(B | A, J, M) * Pr(A | J, M) * Pr(J | M) * Pr(M)$$
- 现在让我们看看能否去除条件集合。



Burglary Example

Suppose we choose the ordering M, J, A, B, E

MaryCalls

JohnCalls


$$P(J \mid M) = P(J)?$$

$$Pr(E, B, A, J, M) = Pr(E \mid B, A, J, M) * Pr(B \mid A, J, M) * Pr(A \mid J, M) * \textcolor{red}{Pr(J \mid M)} * Pr(M)$$



构建贝叶斯网络的示例

Suppose we choose the ordering M, J, A, B, E



$P(J | M) = P(J)$? No


$P(A | J, M) = P(A | J)$? $P(A | J, M) = P(A)$?

$$Pr(E, B, A, J, M) = Pr(E | B, A, J, M) * Pr(B | A, J, M) * \textcolor{red}{Pr(A | J, M)} * Pr(J | M) * Pr(M)$$



Burglary Example

Suppose we choose the ordering M, J, A, B, E



$P(J | M) = P(J)$? No

$P(A | J, M) = P(A | J)$? $P(A | J, M) = P(A)$? No

$P(B | A, J, M) = P(B | A)$?

$P(B | A, J, M) = P(B)$?

$$Pr(E, B, A, J, M) = Pr(E | B, A, J, M) * \mathbf{Pr(B | A, J, M)} * Pr(A | J, M) * Pr(J | M) * Pr(M)$$



Burglary Example

Suppose we choose the ordering M, J, A, B, E

$P(J | M) = P(J)$? No

$P(A | J, M) = P(A | J)$? $P(A | J, M) = P(A)$? No


$P(B | A, J, M) = P(B | A)$? Yes

$P(B | A, J, M) = P(B)$? No

$P(E | B, A, J, M) = P(E | A)$?

$P(E | B, A, J, M) = P(E | A, B)$?

$$Pr(E, B, A, J, M) = \textcolor{red}{Pr(E | B, A, J, M)} * Pr(B | A, J, M) * Pr(A | J, M) * Pr(J | M) * Pr(M)$$





Burglary Example

Suppose we choose the ordering M, J, A, B, E

$P(J | M) = P(J)$? No

$P(A | J, M) = P(A | J)$? $P(A | J, M) = P(A)$? No


$P(B | A, J, M) = P(B | A)$? Yes

$P(B | A, J, M) = P(B)$? No

$P(E | B, A, J, M) = P(E | A)$? No

$P(E | B, A, J, M) = P(E | A, B)$? Yes

$$Pr(E, B, A, J, M) = Pr(E | B, A, J, M) * Pr(B | A, J, M) * Pr(A | J, M) * Pr(J | M) * Pr(M)$$





Inference in Bayes Nets

贝叶斯网络推断

Given

1) a **Bayes net**

$$\begin{aligned} & \Pr(X_1, X_2, \dots, X_n) \\ &= \Pr(X_n \mid \text{Par}(X_n)) * \Pr(X_{n-1} \mid \text{Par}(X_{n-1})) * \dots * \Pr(X_1 \mid \text{Par}(X_1)) \end{aligned}$$

2) some **Evidence**, E

$E = \{\text{a set of values for some of the variables}\}$

We want to **compute the new probability distribution**

$$\Pr(X_k \mid E)$$

That is, we want to figure out

$$\Pr(X_k = d \mid E) \text{ for all } d \in \text{Dom}[X_k]$$



Examples


- Computing probability of different diseases given symptoms **症状**
- Computing probability of hail storms **冰雹** given different metrological evidence

在这种情况下，获得对未知事件的良好概率估计可以帮助我们更有效地做出响应。(gamble rationally)



Burglary example 回到入室盗窃例子

In the Alarm example*** we have (the compact network):



Recall Burglary(B), Earthquake(E), Alarm(A), MaryCalled (M), JohnCalled(J) And from our Bayes Net above, we determined:

$$\Pr(B,E,A,M,J) = P(J|A) * \Pr(M|A) * \Pr(A|E,B) * \Pr(E) * \Pr(B)$$

We might want to compute things like:


$$\Pr(B=True | M=true, J=false, E=false)$$

The probability that there was a burglary, given that Mary called, John didn't call, and there was no earthquake

Burglary example calculation 试一下

B	P(B)
+b	0.001
-b	0.999

A	J	P(J A)
+a	+j	0.9
+a	-j	0.1
-a	+j	0.05
-a	-j	0.95



E	P(E)
+e	0.002
-e	0.998

A	M	P(M A)
+a	+m	0.7
+a	-m	0.3
-a	+m	0.01
-a	-m	0.99



B	E	A	P(A B,E)
+b	+e	+a	0.95
+b	+e	-a	0.05
+b	-e	+a	0.94
+b	-e	-a	0.06
-b	+e	+a	0.29
-b	+e	-a	0.71
-b	-e	+a	0.001
-b	-e	-a	0.999

$$P(+b, -e, +a, -j, +m) =$$

$$P(+b)P(-e)P(+a|+b, -e)P(-j|+a)P(+m|+a) =$$

$$0.001 \times 0.998 \times 0.94 \times 0.1 \times 0.7$$

它表明变量之间的**独立性**可以减少计算量!



谢谢大家!